

Mapa conceptual del flujo de trabajo reproducible

Duración de la titulación en el pregrado universitario chileno, cohorte de titulados 2025

Integrantes (Grupo 6): Fernanda Ovalle · Sebastián Cajales Cid · César Lorca Bacián

Docente: Dr. Omar Salinas Silva · Magíster en Ciencia de Datos e Inteligencia Artificial · Septiembre de 2026

1. Problemática, pregunta analizable y conjunto de datos

Situación. En Chile la duración real de las carreras universitarias suele superar la formal, con costos para estudiantes e instituciones. El Mineduc publica cada año los registros de titulados, pero no está claro qué características de la carrera y la institución acompañan una titulación más larga.

Pregunta analizable. ¿Qué factores observables —tipo de universidad (CRUCH/privada), jornada, modalidad, área de conocimiento, región de la sede, sexo y rango etario— se asocian a un mayor número de semestres hasta la obtención del título (`dur_total_carr`) entre los titulados de pregrado universitario de 2025?

Alcance. Solo pregrado universitario (quedan fuera IP, CFT, postítulos y posgrados). Análisis descriptivo y de asociación; sin modelos predictivos.

Conjunto de datos. Titulados de Educación Superior 2025, Datos Abiertos Mineduc (fuente pública, licencia abierta; CSV con separador «;», UTF-8). Base completa: 328.998 filas × 40 columnas, 175,6 MB. Subconjunto versionado: pregrado universitario, 105.063 filas, 55,8 MB (bajo el límite de GitHub); el filtro se documenta como decisión técnica en el notebook F1.

Salida del validador (subconjunto). Nominales: `region_sede`, `area_conocimiento`, `tipo_inst_2` · ordinales: `rango_edad`, `nivel_carrera_1` · binaria: `gen_alu` · fecha: `fecha_obtencion_titulo` · alta cardinalidad: `nomb_carrera`, `nomb_inst` · numéricas: `dur_estudio_carr`, `dur_proceso_tit`, `dur_total_carr` (semestres). Faltantes: `nombre_titulo` 2,9 %, `nombre_grado` 8,0 %; `anio_ing_carr_ori` = 1900 en 12,7 % de las filas (código «sin información»: obliga a decidir entre eliminar e imputar); 3 duplicados. Informe completo: `docs/validacion_subconjunto.md`.

2. Reflexión técnica del equipo

Elegimos este ecosistema porque cada pieza cubre una condición distinta de la reproducibilidad que exige la Fase 1. Python con entorno virtual y `requirements.txt` fija las versiones para que el mismo notebook dé el mismo resultado en los tres computadores del grupo. Jupyter reúne código, salidas y celdas narrativas, y nos permite documentar en nivel justificativo —no solo qué hicimos, sino por qué— cada decisión sobre nulos, códigos «1900», duplicados y variables ordinales. Git registra esas decisiones como historial con autoría; GitHub aloja el repositorio común con commits identificables por integrante. Descartamos Docker, GitHub Actions y un modelo predictivo: no aportan a las Fases 1 y 2 y obligarían a sostener lo que no vamos a implementar.

Decisiones pendientes para la Fase 2: (a) tratar `anio_ing_carr_ori` = 1900 como faltante y comparar eliminación frente a imputación por mediana según su efecto en la dispersión; (b) definir si `dur_*` se trata como magnitud continua o como recuento de semestres; (c) declarar el orden de `rango_edad` y `nivel_carrera_1` antes de codificar; (d) agrupar categorías raras de `nomb_carrera`; (e) acordar ramas por integrante y fase y activar `nbstripout` en los tres equipos.

3. Referencias (APA 7)

Ministerio de Educación de Chile. (2026). Titulados de educación superior 2025 [Conjunto de datos]. Datos Abiertos Mineduc. <https://datosabiertos.mineduc.cl/>

Novak, J. D., & Cañas, A. J. (2008). The theory underlying concept maps and how to construct and use them (Technical Report IHMC CmapTools 2006-01 Rev 01-2008). Florida Institute for Human and Machine Cognition.

Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology*, 13(6), e1005510. <https://doi.org/10.1371/journal.pcbi.1005510>

